MASTER 2
ÉCONOMÉTRIE ET STATISTIQUES

Cours SAS

GRANDE ÉCOLE D'ACTUARIAT ET DE GESTION DES RISQUES

INSTITUT DE SCIENCE FINANCIÈRE ET D'ASSURANCES

Rapport de projet - Programmation SAS

Analyse des Transactions Immobilières

Modélisation statistique : approches linéaire, robuste et logistique

*Ce rapport présente une analyse complète du marché immobilier danois à partir d'un jeu de données de **100 000 transactions**. Après filtrage sur l'année 2023, **5 540 observations** ont été retenues. L'étude couvre quatre axes : l'analyse exploratoire descriptive, la construction de variables catégorielles, la modélisation linéaire du prix d'achat (MCO et estimation robuste), et la modélisation logistique de la probabilité d'appartenir au segment « haut de gamme » (prix > 900 000 DKK).*

Réalisé par :

ASSOUMANA KALME ANZA

Abdoul Barik

Année Universitaire 2024–2025

Table des matières

1 Présentation des données et préparation **2**
1.1 Description du jeu de données brut . . . 2
1.2 Filtrage et construction des variables . . . 2
1.2.1 Extraction des transactions 2023 . . . 2
1.2.2 Reconstitution de la surface . . . 2

2 Analyse exploratoire **3**
2.1 Distribution de la surface par année de construction . . . 3
2.2 Relation entre la surface et le prix d'achat . . . 4
2.3 Heatmap : nombre de pièces et prix d'achat . . . 5

3 Construction de variables catégorielles et analyse bivariée **6**
3.1 Variable de prix : *Cher / Pas cher* . . . 6
3.2 Catégories par année de construction . . . 6
3.3 Tableau de contingence et test du Khi-deux . . . 6

4 Modélisation linéaire du prix d'achat **7**
4.1 Spécification du modèle . . . 7
4.2 Résultats MCO (`PROC GLM`) . . . 7
4.2.1 Qualité d'ajustement globale . . . 7
4.2.2 Estimations des paramètres (Type III SS) . . . 7
4.3 Régression robuste (`PROC ROBUSTREG`) . . . 8
4.3.1 Statistiques descriptives robustes . . . 8
4.3.2 Estimations robustes . . . 9

5 Modélisation logistique — probabilité d'un prix élevé **10**
5.1 Construction de la variable cible . . . 10
5.2 Modèle avec log(sqm) — modèle principal . . . 10
5.2.1 Ajustement global . . . 10
5.2.2 Coefficients et rapports de cotes . . . 10
5.3 Courbe ROC et performance discriminante . . . 11

6 Évaluation du modèle logistique **13**
6.1 Matrice de confusion (seuil = 0,5) . . . 13
6.2 Heatmap des probabilités prédites . . . 14

7 Synthèse et conclusion **15**
7.1 Récapitulatif des résultats . . . 15
7.2 Conclusions principales . . . 15
7.3 Perspectives . . . 15

1 Présentation des données et préparation

1.1 Description du jeu de données brut

Le fichier source `Data_TP_6.csv` contient **100 000 observations** et **19 variables**. La procédure `PROC CONTENTS` confirme l'absence de données manquantes sur l'ensemble des variables numériques d'intérêt. Le tableau 1 résume les variables retenues pour l'analyse.

Table 1 – Variables sélectionnées pour l'analyse

Variable	Type	Description
`house_type`	Catégorielle	Type de bien (Apartment, Farm, Summerhouse, Townhouse, Villa)
`no_rooms`	Numérique	Nombre de pièces
`purchase_price`	Numérique	Prix d'achat en couronnes danoises (DKK)
`sqm_price`	Numérique	Prix par m^2 (DKK/m^2)
`year_build`	Numérique	Année de construction
`sqm`	Numérique	Surface en m^2 (reconstituée)

1.2 Filtrage et construction des variables

1.2.1 Extraction des transactions 2023

Le filtre `year = year(date); if year = 2023` a permis de réduire l'échantillon à **5 540 transactions**. Ce sous-ensemble constitue la base de toutes les analyses présentées dans ce rapport.

1.2.2 Reconstitution de la surface

La variable `sqm` (surface en m^2) a été reconstruite à partir du rapport :

$$\texttt{sqm} = \frac{\texttt{purchase_price}}{\texttt{sqm_price}}$$

Cette étape est justifiée par le fait que les deux composantes (`purchase_price` et `sqm_price`) sont disponibles sans valeurs manquantes. La variable reconstituée est cohérente avec les statistiques descriptives observées ($\bar{x} = 121{,}2$ m^2).

Résultat clé

Surface moyenne : **121,2 m^2** | Variance : **2 827,86** m^4

L'écart-type ($\approx 53{,}2$ m^2) révèle une forte hétérogénéité dans les tailles des biens échangés en 2023.

2 Analyse exploratoire

2.1 Distribution de la surface par année de construction

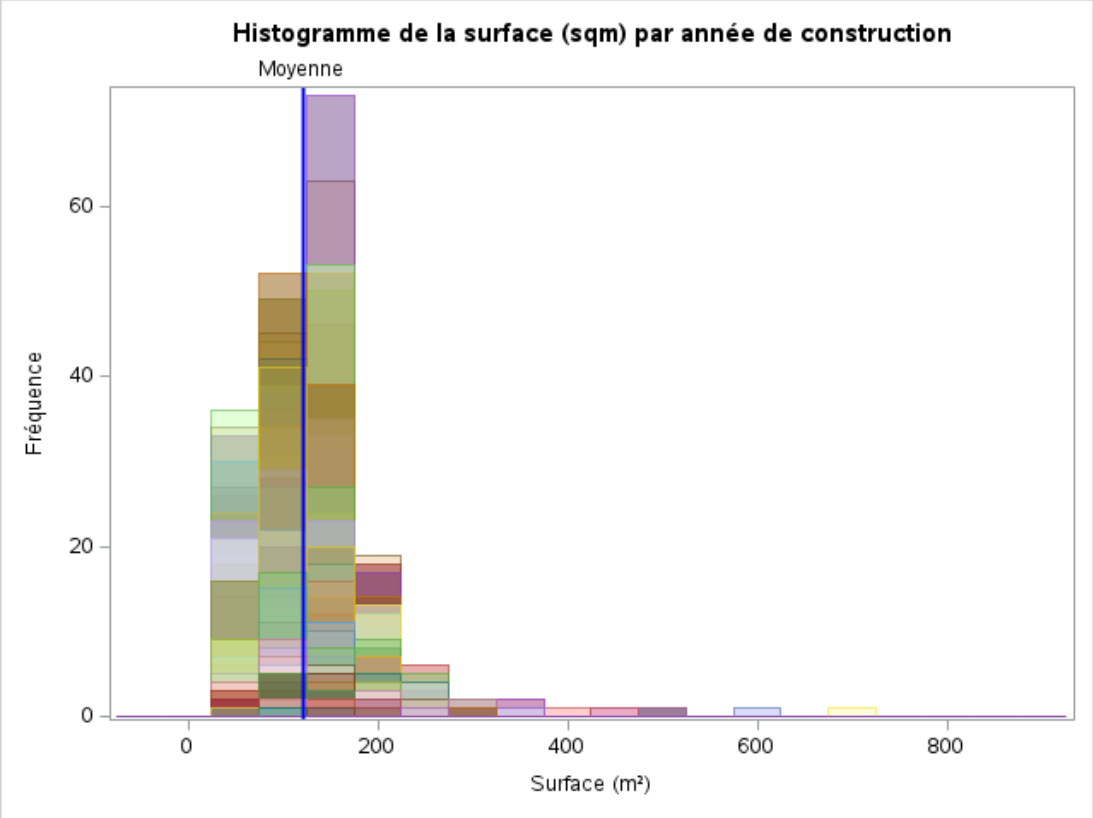

FIGURE 1 – Histogramme de la surface (m^2) par année de construction, avec ligne de référence pour la moyenne (bleu) et la variance (rouge, trait discontinu). Source : `PROC SGPLOT` — données `immo2023`.

Interprétation : L'histogramme révèle une distribution unimodale et asymétrique à droite de la surface des biens. La majorité des transactions porte sur des biens entre 60 et 180 m^2, avec un pic autour de 100–120 m^2. La forte variance (2 827,86 m^4) s'explique par la présence de quelques biens de très grande surface (fermes, villas). Le regroupement par année de construction montre que les biens les plus anciens (antérieurs à 1965) couvrent une gamme de surfaces plus étendue, tandis que les constructions récentes sont plus homogènes en taille.

2.2 Relation entre la surface et le prix d'achat

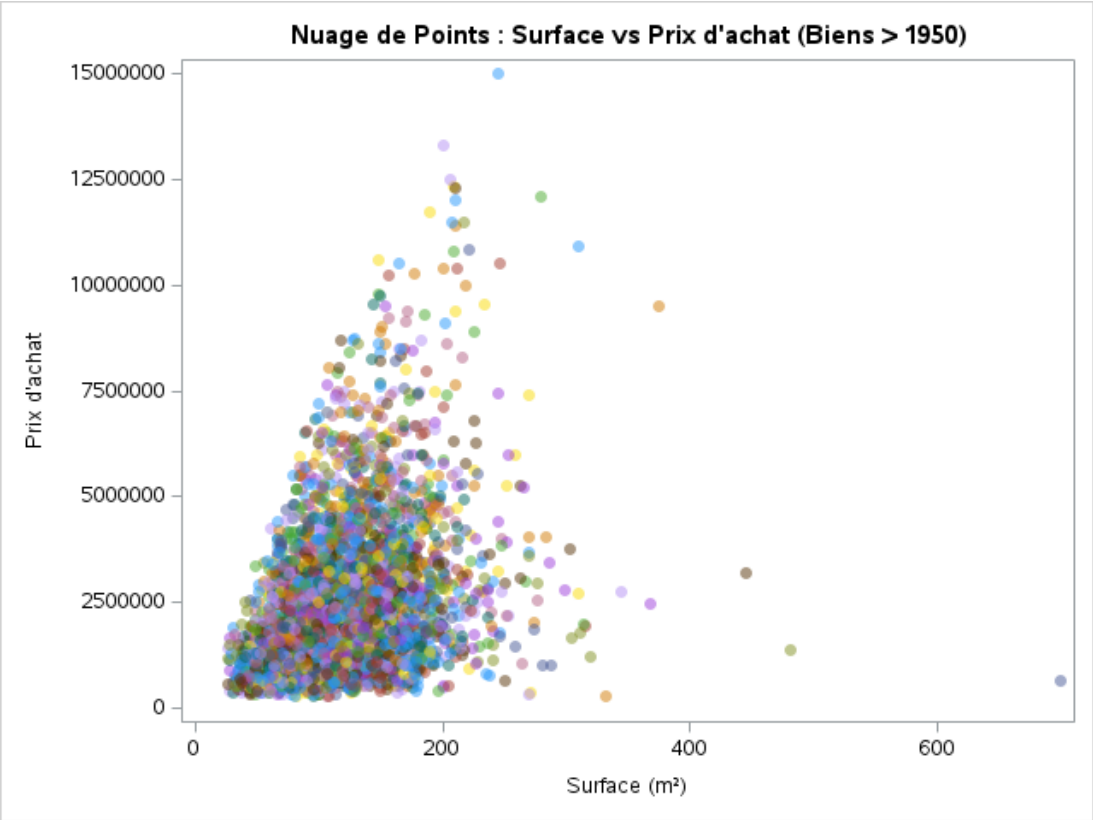

FIGURE 2 – Nuage de points de la surface (m^2) en fonction du prix d'achat (DKK), coloré par année de construction. Transactions postérieures à 1950.

Interprétation : La relation entre la surface et le prix d'achat est clairement **positive et non linéaire** : à mesure que la surface augmente, les prix croissent de façon plus que proportionnelle, ce qui justifie l'utilisation du logarithme de la surface dans la modélisation. On observe également un effet de l'année de construction : les biens récents tendent à se positionner dans les prix plus élevés à surface égale, suggérant un effet d'actualisation lié à la modernité du bien. La dispersion importante aux grandes surfaces illustre l'hétérogénéité du segment haut de gamme.

2.3 Heatmap : nombre de pièces et prix d'achat

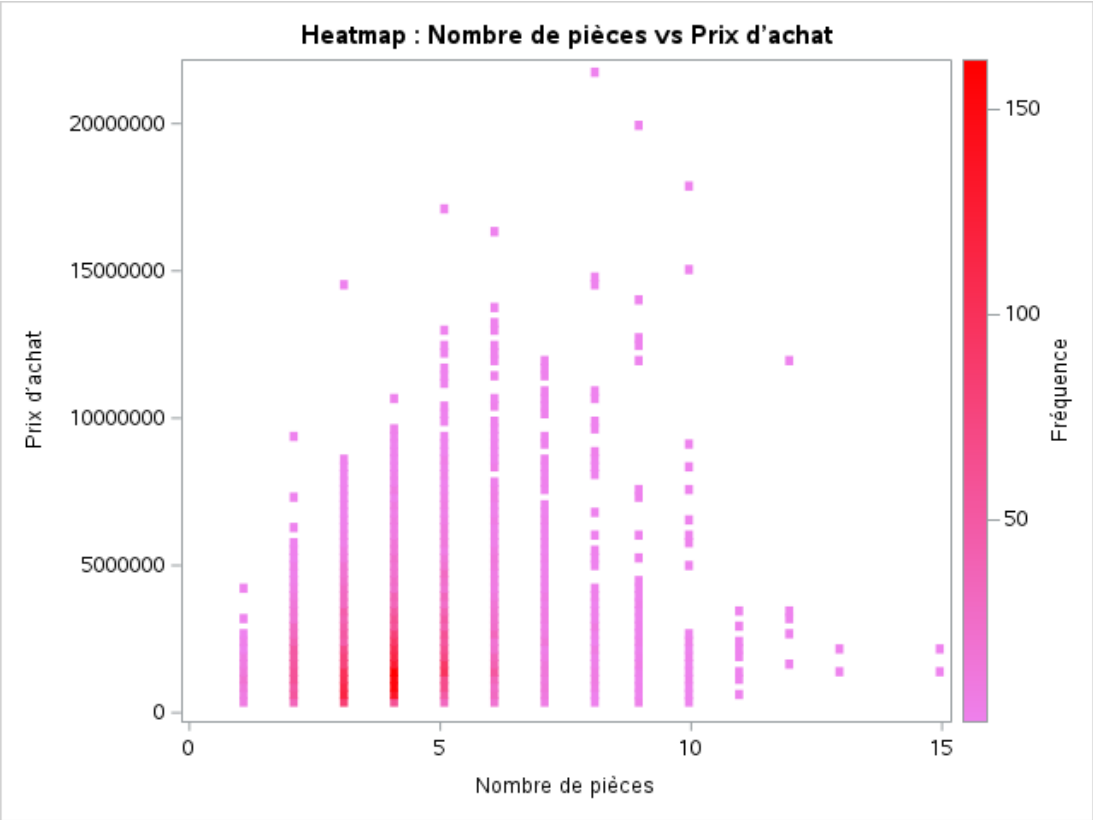

FIGURE 3 – Carte de chaleur croisant le nombre de pièces et le prix d'achat (DKK). L'intensité de la couleur (violet à rouge) représente la densité des observations.

Interprétation : La heatmap confirme que les transactions les plus fréquentes concernent des biens de **3 à 5 pièces** dans une gamme de prix entre 1 et 4 millions de DKK. Les biens avec un grand nombre de pièces (6+) sont plus rares et affichent une plus grande dispersion des prix. La concentration de la densité dans le quadrant « 3–5 pièces / 1–3 M DKK » définit le profil type d'un bien immobilier vendu au Danemark en 2023.

3 Construction de variables catégorielles et analyse bivariée

3.1 Variable de prix : *Cher / Pas cher*

Une variable binaire `price` a été construite selon le critère :

$$\texttt{price} = \begin{cases} \text{“cher”} & \text{si } \texttt{sqm_price} > 18\,000 \text{ DKK/m}^2 \\ \text{“pas cher”} & \text{sinon} \end{cases}$$

3.2 Catégories par année de construction

La variable `year_cat` a été créée en découpant l'année de construction selon les **quintiles** de sa distribution (quantiles à 20%, 40%, 60%, 80%), produisant cinq catégories : avant 1965, 1965–1971, 1971–1977, 1977–2001, et après 2001.

3.3 Tableau de contingence et test du Khi-deux

Table 2 – Tableau de contingence : Prix vs Catégorie d'année de construction

Prix	**+2001**	**–1965**	**–1971**	**–1977**	**–2001**	**Total**
Cher	736	513	628	515	404	**2 796**
Pas cher	345	607	471	631	690	**2 744**
Total	1 081	1 120	1 099	1 146	1 094	**5 540**

Table 3 – Statistiques du test du Khi-deux (4 degrés de liberté)

Statistique	**Valeur**	**p-value**
Khi-deux de Pearson	257,79	$< 0{,}0001$
Rapport de vraisemblance	262,00	$< 0{,}0001$
Khi-deux de Mantel-Haenszel	172,77	$< 0{,}0001$
V de Cramér	0,2157	—

Interprétation : Le test du Khi-deux ($\chi^2 = 257{,}79$, $p < 0{,}0001$) rejette très fortement l'hypothèse d'indépendance entre la catégorie de prix et la période de construction. L'association est **statistiquement significative**, bien que d'intensité modérée ($V = 0{,}216$).

En analysant les fréquences par colonne, on observe un gradient temporel clair : les biens **construits après 2001** sont majoritairement classés “chers” (736 vs 345), tandis que les biens **d'avant 1965** sont majoritairement “pas chers” (607 vs 513). Ce phénomène reflète l'effet conjugué de la modernité des équipements, des normes d'isolation thermique et de la localisation géographique souvent plus favorable des constructions récentes.

4 Modélisation linéaire du prix d'achat

4.1 Spécification du modèle

Le modèle de régression linéaire estimé par les Moindres Carrés Ordinaires (MCO) est :

$$\texttt{purchase_price}_i = \beta_0 + \beta_1 \cdot \texttt{year_build}_i + \beta_2 \cdot \log(\texttt{sqm}_i) + \beta_3 \cdot \texttt{no_rooms}_i + \sum_k \gamma_k \cdot \mathbf{1}[\texttt{house_type}_i = k] + \varepsilon_i$$

La transformation logarithmique de la surface ($\log(\texttt{sqm})$) est justifiée par la relation non linéaire observée dans le nuage de points (cf. figure 2).

4.2 Résultats MCO (PROC GLM)

4.2.1 Qualité d'ajustement globale

Table 4 – Tableau ANOVA — Régression MCO

Source	DDL	SC	CM	F	p-value
Modèle	7	$4{,}13 \times 10^{15}$	$5{,}90 \times 10^{14}$	184,16	$< 0{,}0001$
Erreur	5 532	$1{,}77 \times 10^{16}$	$3{,}20 \times 10^{12}$	—	—
Total	5 539	$2{,}18 \times 10^{16}$	—	—	—
$R^2 = 0{,}1890$	Racine MSE = 1 789 559 DKK			$\bar{y} = 2\,513\,115$ DKK	

4.2.2 Estimations des paramètres (Type III SS)

Table 5 – Coefficients estimés par MCO — effets Type III

Paramètre	Estimation	Erreur std.	t	p-value
Constante	−9 865 447	1 056 325	−9,34	$< 0{,}0001$
`year_build`	1 101,86	514,56	2,14	0,0323
log(`sqm`)	1 967 196	101 788	19,33	$< 0{,}0001$
`no_rooms`	91 375	24 939	3,66	0,0003
house_type Apartment	+1 793 463	74 350	24,12	$< 0{,}0001$
house_type Farm	+481 357	130 103	3,70	0,0002
house_type Summerhouse	+450 781	90 173	5,00	$< 0{,}0001$
house_type Townhouse	+936 524	85 386	10,97	$< 0{,}0001$
house_type Villa	(référence)	—	—	—

Note : Les estimations des effets `house_type` *ne sont pas uniques (matrice $X'X$ singulière) ; elles s'interprètent relativement à la modalité de référence Villa.*

Interprétation des coefficients MCO :

- **Surface (log)** : déterminant le plus important ($F = 373{,}51$, $p < 0{,}0001$). Une augmentation de 1% de la surface accroît le prix d'environ 19 672 DKK.
- **Année de construction** : effet positif et significatif ($\hat{\beta}_1 = 1\,102$ DKK/an, $p = 0{,}032$). Chaque année de construction plus récente valorise le bien de 1 102 DKK.
- **Nombre de pièces** : effet positif et significatif (+91 375 DKK par pièce, $p = 0{,}0003$).
- **Type de bien** : par rapport aux villas (référence), les appartements bénéficient d'une prime de +1,79 M DKK, reflet de leur localisation urbaine à forte valeur foncière.
- **Qualité globale** ($R^2 = 0{,}189$) : modeste mais attendu dans un contexte où la localisation, l'état du bien et l'orientation — non observés — jouent un rôle majeur. La racine MSE (~1,79 M DKK) suggère la présence d'hétéroscédasticité.

4.3 Régression robuste (`PROC ROBUSTREG`)

Face aux indices d'hétéroscédasticité du modèle MCO, une estimation robuste par **M-estimation** a été conduite.

4.3.1 Statistiques descriptives robustes

Table 6 – Statistiques descriptives robustes des variables du modèle

Variable	Q1	Médiane	Q3	Moyenne	Écart-type	MAD
`year_build`	1 934	1 966	1 978	1 955,1	49,13	31,13
log(`sqm`)	4,407	4,745	5,011	4,706	0,435	0,433
`no_rooms`	3	4	5	4,18	1,602	1,483
`purchase_price`	1 195 000	1 965 000	3 250 000	2 513 115	1 985 901	1 391 422

MAD : Déviation Absolue par rapport à la Médiane.

4.3.2 Estimations robustes

TABLE 7 – Coefficients estimés par M-estimation robuste

Paramètre	**Estimation**	**Erreur std.**	χ^2	**p-value**
Constante	−14 060 000	759 221	342,86	< 0,0001
`year_build`	4 773,24	369,83	166,58	< 0,0001
log(`sqm`)	1 349 765	73 159	340,40	< 0,0001
`no_rooms`	14 444,20	17 925	0,65	0,4203
house_type Apartment	+1 476 939	53 438	763,87	< 0,0001
house_type Farm	+133 588	93 510	2,04	0,1531
house_type Summerhouse	+261 251	64 811	16,25	< 0,0001
house_type Townhouse	+816 899	61 370	177,18	< 0,0001
$r^2 = 0{,}1277$ | Échelle ($\hat{\sigma}$) : 1 204 281 DKK | AICR : 6 605,96				

5,45% des observations identifiées comme aberrantes (seuil = 3,0).

Comparaison MCO vs Robuste — enseignements clés :

- **Année de construction** : le coefficient robuste (4 773 DKK/an) est **4,3 fois plus élevé** que le coefficient MCO (1 102 DKK/an). Les biens atypiques atténuaient l'effet réel de l'ancienneté dans le MCO.
- **Nombre de pièces** : devient **non significatif** en robuste ($p = 0{,}42$), indiquant que son effet apparent en MCO était capté par des biens atypiques.
- **Surface (log)** : positif et très significatif dans les deux modèles, confirmant sa robustesse comme déterminant fondamental.
- **5,45% d'observations aberrantes** détectées, ce qui justifie pleinement l'estimateur robuste.
- Le r^2 plus faible (0,128 vs 0,189) est attendu : l'estimateur robuste minimise l'influence des points extrêmes.

5 Modélisation logistique — probabilité d'un prix élevé

5.1 Construction de la variable cible

Une variable binaire `high_price` a été construite :

$$\texttt{high_price}_i = \mathbf{1}[\texttt{purchase_price}_i > 900\,000 \text{ DKK}]$$

Le profil de réponse révèle un fort **déséquilibre des classes** :

- `high_price = 1` (prix > 900 K DKK) : **4 647 observations (83,9%)**
- `high_price = 0` (prix ≤ 900 K DKK) : **893 observations (16,1%)**

5.2 Modèle avec log(sqm) — modèle principal

$$\log\left(\frac{P(\texttt{high_price}=1)}{1-P(\texttt{high_price}=1)}\right) = \beta_0+\beta_1\cdot\texttt{year_build}+\beta_2\cdot\log(\texttt{sqm})+\beta_3\cdot\texttt{no_rooms}+\sum_k \gamma_k\cdot\mathbf{1}[\texttt{house_type}=k$$

5.2.1 Ajustement global

Table 8 – Critères d'ajustement — modèle logistique (avec log sqm)

Critère	Constante seule	Modèle complet
AIC	4 895,37	4 328,39
BIC	4 901,99	4 381,35
$-2\log L$	4 893,37	4 312,39

Le test du rapport de vraisemblance ($LR = 580{,}98$, DDL= 7, $p < 0{,}0001$) confirme la très haute significativité globale du modèle.

5.2.2 Coefficients et rapports de cotes

Table 9 – Coefficients estimés et rapports de cotes — modèle logistique principal

Paramètre	Estim.	Err. std.	χ^2 Wald	p-value	OR [IC 95%]
Constante	−21,594	1,858	135,06	< 0,0001	—
`year_build`	0,00721	0,000920	61,39	< 0,0001	1,007 [1,005 ; 1,009]
log(`sqm`)	1,9907	0,1690	138,81	< 0,0001	7,321 [5,257 ; 10,195]
`no_rooms`	0,0418	0,0431	0,94	0,3319	1,043 [0,958 ; 1,135]
Apartment vs Villa	1,5196	0,1147	175,60	< 0,0001	11,008 [8,267 ; 14,659]
Farm vs Villa	−0,5500	0,1896	8,42	0,0037	1,390 [0,891 ; 2,168]
Summerhouse vs Villa	−0,3032	0,1073	7,99	0,0047	1,779 [1,369 ; 2,312]
Townhouse vs Villa	0,2127	0,1246	2,91	0,0879	2,980 [2,205 ; 4,026]

Interprétation des rapports de cotes :

- **Surface (log)** : prédicteur le plus puissant. Une unité supplémentaire de log(`sqm`) multiplie les cotes par **7,32** (IC 95% : [5,26 ; 10,20]).
- **Année de construction** : effet significatif mais faible ($OR = 1{,}007$). Sur 50 ans : $1{,}007^{50} \approx 1{,}42$.
- **Nombre de pièces** : non significatif ($p = 0{,}332$) ; la surface capte l'essentiel de cette information.
- **Apartment vs Villa** : cotes **11 fois plus élevées**, reflet de la concentration des appartements en zones urbaines à forte valeur.
- **Townhouse vs Villa** : cotes $\times 2{,}98$, mais non significatif à 5% ($p = 0{,}088$).
- **Farm vs Villa** : intervalle de confiance incluant 1, incertitude notable.

5.3 Courbe ROC et performance discriminante

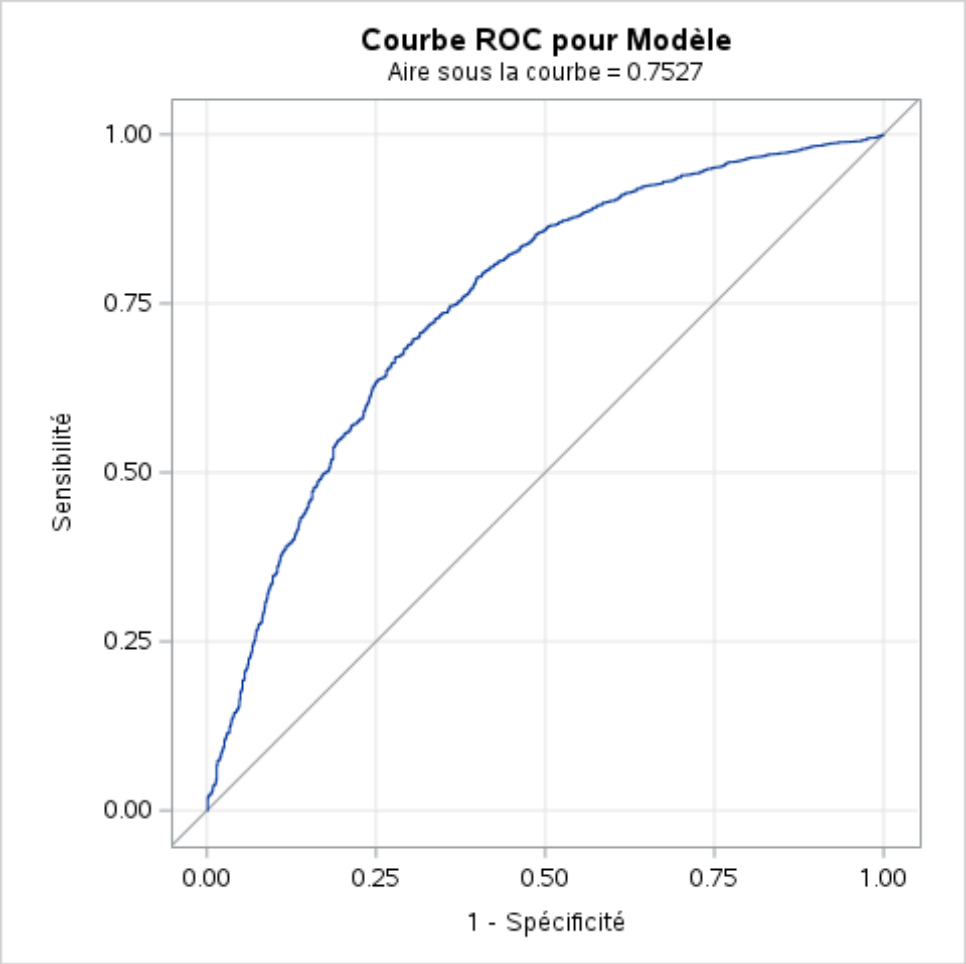

FIGURE 4 – Courbe ROC du modèle logistique comparée au modèle nul (diagonale).

Résultat clé

AUC = 0,7527 (IC 95% Wald : [0,7347 ; 0,7706])

Statistique $c = 0{,}7527$ | D de Somers = 0,505 | $\Gamma = 0{,}505$

Interprétation de la courbe ROC : Une AUC de **0,753** indique un pouvoir discriminant **satisfaisant à bon**. Le modèle est nettement supérieur à un classifieur aléatoire (AUC = 0,5). Le D de Somers (= 0,505) signifie que pour une paire discordante sur deux, le modèle classe correctement le bien à prix élevé avant le bien à prix bas. Ce résultat est robuste compte tenu du déséquilibre des classes.

6 Évaluation du modèle logistique

6.1 Matrice de confusion (seuil = 0,5)

Table 10 – Matrice de confusion — seuil de classification à 0,5

		Classe prédite		
		0	**1**	**Total réel**
Classe réelle	**0** (non haut de gamme)	**72**	821	893
	1 (haut de gamme)	64	**4 583**	4 647
	Total prédit	136	5 404	**5 540**

Table 11 – Indicateurs de performance du classifieur (seuil = 0,5)

Indicateur	**Valeur**
Précision globale (Accuracy)	$(72 + 4\,583)/5\,540 = \mathbf{84{,}0}\%$
Sensibilité (Recall, classe 1)	$4\,583/4\,647 = \mathbf{98{,}6}\%$
Spécificité (Recall, classe 0)	$72/893 = \mathbf{8{,}1}\%$
Faux négatifs (classe 1 mal classée)	64
Faux positifs (classe 0 mal classée)	821

Interprétation de la matrice de confusion :
Le modèle présente une **excellente sensibilité** (98,6%) pour détecter les biens à prix > 900 K DKK, mais une **très faible spécificité** (8,1%) pour identifier les biens à prix bas. Ce déséquilibre s'explique directement par l'asymétrie des classes : avec 84% de la classe 1, un classifieur naïf prédirait systématiquement la classe 1 et atteindrait déjà 84% de précision globale.

Recommandation : Pour un usage opérationnel, il serait pertinent d'abaisser le seuil de classification (par exemple à 0,3 ou 0,4) ou d'utiliser une pondération des classes, afin d'améliorer la spécificité. Le test du Khi-deux ($\chi^2 = 139{,}81$, $p < 0{,}0001$) confirme que les prédictions ne sont pas indépendantes des observations réelles.

6.2 Heatmap des probabilités prédites

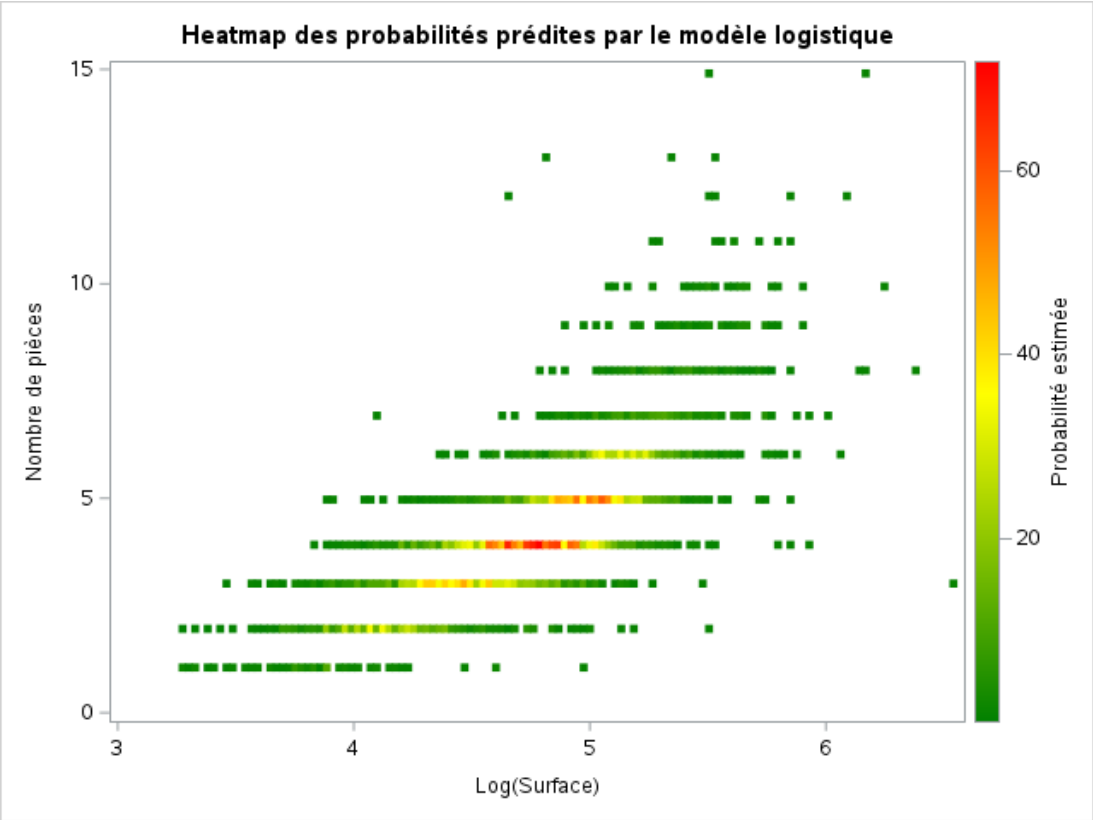

FIGURE 5 – Carte de chaleur des probabilités prédites par le modèle logistique. L'intensité de la couleur (vert = faible probabilité, rouge = probabilité élevée) représente $\hat{P}(\texttt{high_price} = 1)$.

Interprétation : La heatmap illustre la combinaison de log(`sqm`) et du nombre de pièces associée à une forte probabilité de prix > 900 K DKK. Les zones rouges se concentrent dans les valeurs élevées de log(`sqm`), confirmant l'importance prédominante de la surface. Le nombre de pièces apporte une modulation secondaire : à surface égale, les biens avec davantage de pièces tendent vers des probabilités légèrement plus élevées.

7 Synthèse et conclusion

7.1 Récapitulatif des résultats

Table 12 – Synthèse des modèles estimés

Critère	MCO (GLM)	Robuste	Logistique
Variable cible	`purchase_price`	`purchase_price`	`high_price`
R^2 / AUC	0,189	0,128 (r^2)	0,753 (AUC)
Meilleur prédicteur	log(`sqm`)	log(`sqm`)	log(`sqm`)
Effet `no_rooms`	Sig. ($p = 0{,}0003$)	Non sig. ($p = 0{,}42$)	Non sig. ($p = 0{,}33$)
Effet `year_build`	Sig. ($p = 0{,}032$)	Très sig. ($p < 0{,}0001$)	Sig. ($p < 0{,}0001$)

7.2 Conclusions principales

1. **La surface est le déterminant universel du prix immobilier.** La surface (en log) est le prédicteur dominant dans tous les modèles estimés.
2. **L'année de construction joue un rôle significatif, amplifié par l'estimation robuste.** L'effet réel est nettement positif : les biens plus récents sont systématiquement mieux valorisés.
3. **Le type de bien structure fortement le marché.** Les appartements présentent les prix les plus élevés, reflet de leur localisation urbaine.
4. **Le nombre de pièces n'est pas un déterminant robuste du prix.** Significatif en MCO, il disparaît dans le modèle robuste et le modèle logistique.
5. **Le modèle logistique offre un pouvoir discriminant satisfaisant (AUC = 0,753)**, mais souffre du déséquilibre des classes. Un ajustement du seuil améliorerait significativement la spécificité.

7.3 Perspectives

Pour approfondir cette analyse, plusieurs pistes peuvent être envisagées :

→ Intégrer des variables géographiques (région, code postal) pour capturer les effets de localisation.

→ Tester des modèles non linéaires (forêts aléatoires, gradient boosting) pour améliorer la discrimination logistique.

→ Appliquer une technique de ré-échantillonnage (SMOTE) pour traiter le déséquilibre des classes.

→ Étendre l'analyse à plusieurs années afin d'étudier la dynamique temporelle du marché.

Rapport réalisé avec SAS OnDemand for Academics — ASSOUMANA KALME ANZA Abdoul Barik